

[3]Sprawozdanie Zadanie III

Wydział i kierunek:	WIiT, Bioinformatyka
Imię i nazwisko prowadzącego: Prof. Dr. hab. Inż. Marta Kasprzak	Data oddania sprawozdania:
Imię i nazwisko: Kacper Gałaj 163827	Ocena:

1. Opis zastosowanego algorytmu

W programie zastosowałem algorytm **zachłannego budowania kliku** do wyboru najlepszego zestawu pasujących fragmentów sekwencji. Algorytm został wybrany ze względu na prostotę i szybkie działanie. Mimo że nie gwarantuje rozwiązania optymalnego, w praktyce daje poprawne i wystarczająco dobre wyniki.

Poniżej pseudokod demonstrujący podstawowe użycie algorytmu:

Algorytm GreedyMaximalCliqueInGroup

Wejście:

group_nodes, nodes, seq_count, distance_limit

Wyjście:

clique - lista wybranych wierzchołków

1. Dla każdego v w $group_nodes$ oblicz $degree[v]$ jako liczbę kompatybilnych sąsiadów
2. Posortuj $group_nodes$ malejąco według $degree[v]$
3. $clique$ = pusty zbiór
 $used_seq$ = tablica fałsz o rozmiarze seq_count
4. Dla każdego v z posortowanej listy:
jeśli $used_seq[v.seq_index] = false$
i v jest kompatybilny ze wszystkimi w $clique$:
dodaj v do $clique$
 $used_seq[v.seq_index] = true$

5. Zwróć clique

Złożoność algorytmu:

Fragment obliczania stopni wykonuje porównanie każdej pary wierzchołków w danej grupie `group_nodes`, co daje złożoność czasową $O(n^2)$, gdzie k to liczba wierzchołków w grupie.

```
vector<int> degrees(nodes.size(), 0);
for (size_t i = 0; i < group_nodes.size(); ++i) {
    int idx_i = group_nodes[i];
    for (size_t j = i + 1; j < group_nodes.size(); ++j) {
        int idx_j = group_nodes[j];
        if (are_compatible(nodes[idx_i], nodes[idx_j], distance_limit)) {
            degrees[idx_i] += 1;
            degrees[idx_j] += 1;
        }
    }
}
```

Źródło.

O Algorytmie dowiedziałem się przez film na youtube z kanału "Wrath of Math" autor przechodzi od tłumaczenia czym są Kliki, oraz tłumaczy w pełni działanie tego oto algorytmu.

<https://www.youtube.com/watch?v=gjRcTH2p65c> - Maksymalna Klika

<https://www.youtube.com/watch?v=nBrFC0STAp0> - Czym są kliki

[1] TEST: Identyczny motyw (cel bazowy)

Instancja nr 1 [seq1] Użyty motyw:

ATTAGCTTATACGTGG

Cel:

Sprawdzić, czy algorytm potrafi wykryć wspólny, niezmienny motyw obecny po jednym razie w każdej sekwencji po filtracji jakości. To jest punkt odniesienia do późniejszych testów z mutacjami i różnymi parametrami.

▼ Fasta

```

>DOJHLOP02GVZDE length=96 xy=2707_2112 region=2 run=R_2005_09_08_15_
35_38_
T T A C T T A T G T T T G A A C A T A G T G T T A T T A G C T T A T A C G T G G C T G A A G C T T G T G C T T C G
A T T
C T A T G G A G G G A T G C T G G C A A G G C T C C G G A A G C A G C A
>DOJHLOP01BGY5C length=99 xy=0486_1118 region=1 run=R_2005_09_08_15_3
5_38_
T T C C C C T A T T A C A A T T A G C T T A T A C G T G G C T T T A A G C C T A A A C A T T T C T C G T A G A T T
C A C
T G C G A T T G C C T C T C C T T G T C C T T G T T C T T C T G C T A T G A G
>DOJHLOP01BP4NK length=113 xy=0590_2174 region=1 run=R_2005_09_08_15_
35_38_
C A T G G T C C A T C A G C C T C A A A G C C T T T C T G T A G C C T C C A G G T T T T G A T T A G C T T A T A
C G T G
G T G C A A C A T T C T C T T T T G T A T C T C T T A C C T T T T T G T T G T C C A A T T A A A A G G
>DOJHLOP01ANFAH length=102 xy=0149_2711 region=1 run=R_2005_09_08_15_
35_38_
A T T A C A T A C A G A T G T T T T G T G A T G A T T G G G T T G A A T T A C A T A T T A G C T T A T A C G T G G C
T G
A T G A T C A A G C T C T A A T A G G G A G G G T T A G C T C G A A T A G G G T A G
>DOJHLOP01BQUH1 length=94 xy=0598_2903 region=1 run=R_2005_09_08_15_
35_38_
T C T T C T C G C C T T C G T G C T G C A A G T G T T T C T A A T T G C A A A T T A G C T T A T A C G T G G T C
A A C T
T C T G A A T C T C T T G C T A A T T C T C T G A T T T G A T C A A

```

▼ Qual

```

>DOJHLOP02GVZDE length=96 xy=2707_2112 region=2 run=R_2005_09_08_15_
35_38_
26 24 28 31 28 26 31 30 31 29 28 16 32 31 27 30 17 31 30 31 18 32 27 27 ** 18 31
31 17 30 31 31 29 26 32 30 31 26 32 29 28 ** 17 26 27 28 22 30 29 29 26 31 30
31 32 30 27 32 29 27
30 27 31 29 27 28 23 22 30 28 27 18 26 31 27 32 30 31 27 32 29 23 31 27 25 18
29 24 26 24 30 27 31 30 31 32 31 25
>DOJHLOP01BGY5C length=99 xy=0486_1118 region=1 run=R_2005_09_08_15_3
5_38_
29 24 24 24 18 2 30 31 29 24 23 31 24 ** 29 29 24 31 30 30 25 31 27 27 31 26 2
9 24 25 18 ** 31 27 26 13 31 27 30 29 24 32 29 28 17 32 31 27 26 13 32 29 30 31
28 30 28 31 29 24 32
31 31 31 30 29 28 31 28 22 32 30 25 32 32 31 27 20 29 24 31 32 26 20 31 28 30
31 27 30 31 28 32 28 31 32 30 29 26 25 21 27

```

```
>DOJHLOP01BP4NK length=113 xy=0590_2174 region=1 run=R_2005_09_08_15_35_38_
31 29 29 31 28 32 31 28 31 29 29 31 32 30 27 31 30 28 27 15 32 31 28 29 28 18 3
2 32 31 31 31 32 29 26 31 31 28 25 27 25 24 24 22 12 31 ** 28 25 29 31 31 31 27
28 27 19 31 28 28 19 31 28 ** 22 32 29 30 26 31 29 27 25 31 18 31 24 24 21 12 3
0 31 31 32 28 31 28 23 16 31 30 25 20 20 19 16 9 1 31 28 23 31 29 30 26 23 22 2
31 28 24 23 21 12 25 23
>DOJHLOP01ANFAH length=102 xy=0149_2711 region=1 run=R_2005_09_08_15_35_38_
31 30 26 27 31 31 29 26 32 31 31 31 30 32 24 24 22 12 31 25 29 27 32 32 32 31 2
8 28 27 19 30 27 31 31 28 28 26 26 31 31 31 ** 29 26 29 29 31 31 30 24 23 31 28
30 29 27 31 27 ** 32 32 27 32 31 26 32 29 32 31 28 32 24 27 31 21 29 27 32 31
23 22 2 30 28 27 19 30 28 22 32 27 31 32 24 29 27 17 23 23 22 5 31 25 32
>DOJHLOP01BQUH1 length=94 xy=0598_2903 region=1 run=R_2005_09_08_15_35_38_
32 31 31 28 31 31 32 31 27 21 31 27 31 31 32 31 31 31 29 28 26 20 31 24 24 26 25
10 27 29 26 19 31 27 28 29 24 24 ** 18 2 31 30 26 31 31 31 30 31 29 28 22 32 32
31 ** 29 29 26 19 31 31 26 25 15 29 22 13 19 30 27 26 28 23 29 32 25 24 17 31 2
7 31 31 21 29 31 21 29 28 16 25 27 25 28 31 28
```

Proces przetwarzania

- Najpierw odrzuca wszystkie pozycje o **jakości < 25**, tworząc przefiltrowane sekwencje.
- Z przefiltrowanych sekwencji buduje wszystkie k-mery długości **k=6**.
- Dla każdego identycznego k-meru tworzy grupę wierzchołków i łączy je krawędziami, jeśli są z różnych sekwencji i mają zbliżone pozycje ($\leq 10 \cdot k$).
- Następnie algorytm zachłanny wybiera klikę (**po jednym wierzchołku z każdej sekwencji**), maksymalizując rozmiar.

Wynik dla Sekwencji o progu **25 i długości **6**:**

```
./exe3 ./dane/seq1.fasta ./dane/seq1.qual 25 6
Znaleziono strukture o rozmiarze 4:
Sekwencja 2 (DOJHLOP01BGY5C length=99 xy=0486_1118 region=1 run=R_2005_08_15_35_38_), pozycja 17, fragment: AGCTTA
Sekwencja 5 (DOJHLOP01BQUH1 length=94 xy=0598_2903 region=1 run=R_2005_08_15_35_38_), pozycja 42, fragment: AGCTTA
Sekwencja 4 (DOJHLOP01ANFAH length=102 xy=0149_2711 region=1 run=R_2005_09_08_15_35_38_), pozycja 45, fragment: AGCTTA
Sekwencja 3 (DOJHLOP01BP4NK length=113 xy=0590_2174 region=1 run=R_2005_09_08_15_35_38_), pozycja 49, fragment: AGCTTA
```

Wnioski

- Algorytm znalazł wspólny k-mer **AGCTTA** w 4 sekwencjach (2, 5, 4, 3), więc zwrócił strukturę rozmiaru 4.
- Podane pozycje (17, 42, 45, 49) to pozycje startu tego k-meru w oryginalnych sekwencjach.
- Sekwencja 1 nie weszła, bo przy progu 25 w jej przefiltrowanej sekwencji nie ma **AGCTTA**, więc w grafie nie było wierzchołka do dołączenia.
- **AGCTTA** jest fragmentem wstawionego motywu, więc wynik faktycznie wskazuje na motyw, tylko w skróconej postaci (k=6).

[2] TEST: Zależność od długości k-meru (k = 4, 6, 8, 9)

Instancja nr 2 **[seq2]** Użyty motyw:
AGGATCACCTATAT

Cel:

Zbadać wpływ długości podciągu na skuteczność detekcji. Krótsze k-mery powinny być łatwiejsze do znalezienia, ale mniej charakterystyczne (więcej przypadkowych trafień), natomiast dłuższe k-mery są bardziej specyficzne, ale łatwiej „giną” po filtracji jakości lub przez mutacje.

▼ Fasta

```
>DOJHLOP01BDHIH length=100 xy=0446_2135 region=1 run=R_2005_09_08_15_35_38_
GCGCATTGGGGATAGGCGTCGCAGACAGGTTACTTATGTTTGAACATAGTG**AGG
ATCACCTATAT**AGCCCTGAAGCTTGTGCTTCGATTCTATGGAGGGA
>DOJHLOP01DQU8O length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_
GAGCTTATGCAGGGCTCATAGCAGAAGAA**AGGATCACCTATAT**GGCAATCGCA
GTGAATCTACGAGAAATGTTTAGGCTTAAAGTTCCAATAATTGCAA
>DOJHLOP01A0CMG length=110 xy=0296_3670 region=1 run=R_2005_09_08_15_35_38_
TAGTGAAAATTCCGTCCTTTTTTAATTGGACAACAAAAAGGTAGAGATACAAAAGAG
AATG**AGGATCACCTATAT**GGCATGGCAAAACCTGGAGGCTACAAGAAGCTTG
AG
>DOJHLOP02G64JC length=99 xy=2834_1830 region=2 run=R_2005_09_08_15_35_38_
```

```

35_38_
CTATTCGAGCTAACCC**AGGATCACCTATAT**GATCATCAGTTCCGTTCTGTCTC
CATGTAATTC AACCCAATCATCAACAAAACATCTGTATGTAATCG
>DOJHLOP02HLL3Q length=103 xy=2999_1940 region=2 run=R_2005_09_08_15_
35_38_
TACCTTTGATTACTGATAC**AGGATCACCTATAT**ATATTTTAATCAAGACTCTTAA
TAGGTTGCCAGAAAATATGCCGATATGGATGATGCCATCTCAATCGA

```

▼ Qual

```

>DOJHLOP01BDHIH length=100 xy=0446_2135 region=1 run=R_2005_09_08_15_
35_38_
27 32 32 31 32 31 27 25 25 20 7 30 29 32 30 26 31 31 32 31 31 32 24 32 30 31 3
0 31 26 31 27 29 30 31 27 29 32 32 26 25 10 31 22 13 29 30 31 32 31 30 29 ** 29
28 17 29 31 31 31 29 32 30 26 32 31 30 ** 25 31 29 28 17 31 31 24 16 31 32 30 27
30 32 31 31 30 27 32 30 29 31 28 32 30 29 30 24 23 31 28 28 18 25
>DOJHLOP01DQU8O length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_
35_38_
27 26 31 30 30 26 26 30 30 30 29 26 25 11 31 29 32 31 26 30 30 29 28 32 30 27
29 31 27 ** 31 31 28 26 20 30 26 31 28 30 26 31 31 31 ** 27 21 31 30 25 27 31 31
29 30 29 27 28 28 22 31 27 26 22 26 30 20 24 26 25 9 20 26 23 22 3 31 22 13 2
9 31 28 27 27 13 22 22 14 27 21 29 26 29 27 25 21 11 30 31 28 22
>DOJHLOP01A0CMG length=110 xy=0296_3670 region=1 run=R_2005_09_08_15_
35_38_
24 27 17 17 31 24 24 19 4 18 8 18 7 31 30 22 13 22 22 20 13 2 31 28 31 28 27 20 2
0 28 31 27 30 22 22 21 15 5 27 21 28 18 29 23 28 32 31 17 28 26 25 22 11 32 31 3
1 24 17 30 32 ** 31 26 31 24 31 28 31 25 24 8 31 25 25 18 ** 31 26 32 25 32 31 2
6 24 25 25 20 7 27 20 27 27 21 22 21 11 26 25 31 29 21 12 31 23 22 17 23 23 22 2
9 31 18
>DOJHLOP02G64JC length=99 xy=2834_1830 region=2 run=R_2005_09_08_15_
35_38_
31 32 31 31 27 32 31 29 32 31 32 31 27 28 28 18 ** 32 30 27 32 30 31 27 30 31 2
8 31 32 29 26 ** 30 30 32 32 31 27 32 28 29 29 26 27 25 32 30 27 31 27 29 31 2
8 21 27 1 27 28 30 31 25 30 25 31 26 17 31 27 28 28 18 30 26 30 31 32 31 24 22 1
3 31 25 25 22 13 32 26 30 32 32 31 31 32 31 30 32 31 27 28 32 24
>DOJHLOP02HLL3Q length=103 xy=2999_1940 region=2 run=R_2005_09_08_15_
35_38_
32 26 31 26 29 28 16 31 32 31 27 26 29 31 32 32 19 32 32 ** 13 13 13 12 11 8 5 1
32 30 31 32 26 25 ** 22 10 25 21 26 25 22 11 29 27 32 31 30 27 28 32 32 21 32
31 27 24 22 28 32 31 28 27 30 30 24 17 31 24 24 22 13 29 31 25 29 29 24 29 30
32 28 31 31 27 27 31 26 32 30 32 31 27 30 31 30 25 27 30 24 32 32 29 32

```

Wynik dla Sekwencji o progu 25 i długości 4 :

```
> ./exe3 ./dane/seq2.fasta ./dane/seq2.qual 25 4
Znaleziono strukture o rozmiarze 4:
Sekuencja 4 (DOJHLOP02G64JC length=99 xy=2834_1830 region=2 run=R_2005_09_08_15_35_38_), pozycja 23, fragment: ACCT
Sekuencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 36, fragment: ACCT
Sekuencja 5 (DOJHLOP02HLL3Q length=103 xy=2999_1940 region=2 run=R_2005_09_08_15_35_38_), pozycja 18, fragment: ACCT
Sekuencja 1 (DOJHLOP01BDHIH length=100 xy=0446_2135 region=1 run=R_2005_09_08_15_35_38_), pozycja 58, fragment: ACCT
```

Wynik dla Sekwencji o progu 25 i długości 6 :

```
./exe3 ./dane/seq2.fasta ./dane/seq2.qual 25 6
Znaleziono strukture o rozmiarze 4:
Sekuencja 5 (DOJHLOP02HLL3Q length=103 xy=2999_1940 region=2 run=R_2005_09_08_15_35_38_), pozycja 18, fragment: ACCTAT
Sekuencja 4 (DOJHLOP02G64JC length=99 xy=2834_1830 region=2 run=R_2005_09_08_15_35_38_), pozycja 23, fragment: ACCTAT
Sekuencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 36, fragment: ACCTAT
Sekuencja 1 (DOJHLOP01BDHIH length=100 xy=0446_2135 region=1 run=R_2005_09_08_15_35_38_), pozycja 58, fragment: ACCTAT
```

Wynik dla Sekwencji o progu 25 i długości 8 :

```
./exe3 ./dane/seq2.fasta ./dane/seq2.qual 25 8
Znaleziono strukture o rozmiarze 4:
Sekuencja 5 (DOJHLOP02HLL3Q length=103 xy=2999_1940 region=2 run=R_2005_09_08_15_35_38_), pozycja 18, fragment: ACCTATAT
Sekuencja 4 (DOJHLOP02G64JC length=99 xy=2834_1830 region=2 run=R_2005_09_08_15_35_38_), pozycja 23, fragment: ACCTATAT
Sekuencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 36, fragment: ACCTATAT
Sekuencja 1 (DOJHLOP01BDHIH length=100 xy=0446_2135 region=1 run=R_2005_09_08_15_35_38_), pozycja 58, fragment: ACCTATAT
```

Wynik dla Sekwencji o progu 25 i długości 9 :

```
./exe3 ./dane/seq2.fasta ./dane/seq2.qual 25 9
Znaleziono strukture o rozmiarze 3:
Sekuencja 4 (DOJHLOP02G64JC length=99 xy=2834_1830 region=2 run=R_2005_09_08_15_35_38_), pozycja 22, fragment: CACCTATAT
Sekuencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 35, fragment: CACCTATAT
Sekuencja 1 (DOJHLOP01BDHIH length=100 xy=0446_2135 region=1 run=R_2005_09_08_15_35_38_), pozycja 57, fragment: CACCTATAT
```

Wnioski:

- Im większe k , tym trudniej znaleźć wspólny fragment we wszystkich sekwencjach, bo dłuższy k -mer częściej „rozrywa się” po filtracji jakości.
- Krótsze k -mery dają więcej dopasowań, ale są mniej specyficzne; dłuższe są bardziej precyzyjne, ale liczba trafionych sekwencji spada.
- Co ciekawe, przy $k=9$ struktura ma rozmiar tylko 3, bo w dwóch sekwencjach po filtracji jakości **nie zachował się dokładny fragment** CACCTATAT, więc nie mogły wejść do wyniku.
- Wyniki potwierdzają, że dobór k to kompromis między „czułością” (ile sekwencji złapie) a „precyzją” (jak długi i jednoznaczny jest motyw).

[3] TEST: Wpływ progu jakości (20 / 25 / 30) Instancja nr 3 [seq3] Użyty motyw: TATACTTAGATTA

Cel:

Ustalić, dla jakiego progu jakości program jeszcze znajduje motyw w większości sekwencji, a od jakiej wartości progu zaczyna on znikać z wyniku.

▼ Fasta

```
>DOJHLOP02IRJPW length=104 xy=3477_0514 region=2 run=R_2005_09_08_15_35_38_
AATAGGGGAAGGTGGCTCTGGTGGCGCATTGGGGATAGGCGTC**TACACTTACAT
TA**TTATGTTTGAAGATACTTAGATTACAGTTGCAAGCCCTGAAGCTTGTG
>DOJHLOP01DQU8O length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_
GAGCTTATGCAGGGCTCATAGCAGAAGAACAAGGACAAGGAGAGGCA**TAGACTT
ACATTA**TACGAGAAATGTTTAGGCTTAGATACTTAGATTATGCAA
>DOJHLOP02FEHEE length=119 xy=2098_0516 region=2 run=R_2005_09_08_15_35_38_
TCTGTAGCCTCCAGGTTTTGCCATGCCAAAGTTTCTTGCAACATTCTCTTTTGTAT
CTCTACCTTTTTG**TACACTTATATTA**AGGACGGATTTTTCAGATACTTAGATTAA
CCCTC
CTA
>DOJHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_35_38_
AAGGCCTAGCACACTCGATTACATACAGATGTT**TAGACTTATATTA**GTTGAATT
```


ACATGGAGACAGGGATACTTAGATTAATCAAGCTCTAATAGGG

>DOJHLOP01CJL9T length=114 xy=0926_1775 region=1 run=R_2005_09_08_15_3_38_

TTCTCTGATTTGATCAATCTGATTCTCTAATTCAACAAGTAGGTTTTTCAAATTCGAGGAGAAAACGTCTAGCCA**TACACTTAAATTA**TAACCGATACTTAGATTAGTTAATGT

▼ Qual

>DOJHLOP02IRJPW length=104 xy=3477_0514 region=2 run=R_2005_09_08_15_35_38_

31 27 31 28 26 25 22 10 30 25 28 25 29 31 27 32 28 30 32 29 26 30 30 27 32 32 32 31 31 27 25 25 22 12 28 28 32 31 27 31 31 31 30 ** 31 32 30 31 32 27 31 31 26 29 26 32 30 ** 31 27 31 30 32 29 28 17 31 25 18 30 32 28 31 31 24 30 27 27 13 2 7 31 32 31 28 28 31 27 31 30 29 23 32 29 28 18 31 31 24 16 25 30 27 25 24 27 22

>DOJHLOP01DQU8O length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_

27 26 31 30 30 26 26 30 30 30 29 26 25 11 31 29 32 31 26 30 30 29 28 32 30 27 29 31 27 31 31 28 26 20 30 26 31 28 30 26 31 31 31 27 21 31 30 ** 25 27 31 31 29 30 29 7 28 28 22 31 27 ** 26 22 26 30 20 24 26 25 9 20 26 23 22 3 31 22 13 29 31 28 27 27 13 22 22 14 27 21 29 26 29 27 25 21 11 30 31 28 22

>DOJHLOP02FEHEE length=119 xy=2098_0516 region=2 run=R_2005_09_08_15_35_38_

31 32 32 32 31 29 29 31 26 32 31 27 29 31 27 25 25 21 9 32 30 26 31 29 31 30 2 6 27 27 18 31 28 27 15 32 31 26 30 31 30 26 28 30 31 26 31 30 29 25 25 22 10 3 0 30 31 31 32 31 31 22 31 31 27 21 21 20 16 9 32 ** 31 26 27 32 31 27 26 24 31 27 24 24 21 ** 13 31 27 26 32 30 26 31 22 22 21 15 5 31 25 26 19 32 32 27 21 31 31 22 26 32 31 30 27 28 28 18 31 26 19 31 27

>DOJHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_3_38_

31 27 30 25 31 27 31 31 31 30 32 31 32 32 31 31 32 32 31 26 28 28 31 31 29 31 28 32 31 29 29 25 25 ** 22 12 32 31 32 27 31 31 32 28 25 28 27 ** 18 30 27 32 30 2 5 26 24 28 32 32 32 26 24 22 30 32 31 29 27 24 31 27 28 31 26 30 25 31 31 31 3 2 32 30 31 27 32 31 27 30 29 27 25 30 29 27 31 30 24 22 5

>DOJHLOP01CJL9T length=114 xy=0926_1775 region=1 run=R_2005_09_08_15_3_38_

31 28 28 31 32 31 32 32 29 28 18 32 31 29 31 31 28 31 26 32 29 25 31 27 31 31 2 9 25 31 26 31 26 31 31 28 31 30 26 28 11 27 24 16 22 22 21 15 5 32 27 26 13 31 2 8 31 24 31 31 27 18 32 25 24 20 6 30 29 32 30 26 26 32 30 26 26 ** 24 31 7 7 7 6 6 5 4 3 1 1 31 ** 26 30 27 31 28 29 28 18 26 32 22 14 31 31 26 26 24 25 19 31 2 8 31 27 29 31 32

Wynik dla Sekwencji o progu **20** i długości **6** :

```
./exe3 ./dane/seq3.fasta ./dane/seq3.qual 20 6
Znaleziono strukture o rozmiarze 4:
Sekwencja 4 (DOJHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_35_38_), pozycja 75, fragment: AGATTA
Sekwencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 89, fragment: AGATTA
Sekwencja 5 (DOJHLOP01CJL9T length=114 xy=0926_1775 region=1 run=R_2005_09_08_15_35_38_), pozycja 101, fragment: AGATTA
Sekwencja 3 (DOJHLOP02FEHEE length=119 xy=2098_0516 region=2 run=R_2005_09_08_15_35_38_), pozycja 105, fragment: AGATTA
```

Wynik dla Sekwencji o progu **25** i długości **6** :

```
./exe3 ./dane/seq3.fasta ./dane/seq3.qual 25 6
Znaleziono strukture o rozmiarze 3:
Sekwencja 4 (DOJHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_35_38_), pozycja 19, fragment: TTACAT
Sekwencja 1 (DOJHLOP02IRJPW length=104 xy=3477_0514 region=2 run=R_2005_09_08_15_35_38_), pozycja 49, fragment: TTACAT
Sekwencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 53, fragment: TTACAT
```

Wynik dla Sekwencji o progu **30** i długości **6** :

```
./exe3 ./dane/seq3.fasta ./dane/seq3.qual 30 6
Znaleziono strukture o rozmiarze 2:
Sekwencja 4 (DOJHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_35_38_), pozycja 11, fragment: ACACTC
Sekwencja 5 (DOJHLOP01CJL9T length=114 xy=0926_1775 region=1 run=R_2005_09_08_15_35_38_), pozycja 34, fragment: ACACTC
```

Wynik dla Sekwencji o progu **31** i długości **6** :

```
./exe3 ./dane/seq3.fasta ./dane/seq3.qual 31 6
Znaleziono strukture o rozmiarze 2:
Sekwencja 4 (DOJHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_35_38_), pozycja 16, fragment: CGATAT
Sekwencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 46, fragment: CGATAT
```

Wynik dla sekwencji o progu **32** i długości **6** :

```
Znaleziono strukture o rozmiarze 1:
Sekwencja 4 (DOJHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_35_38_), pozycja 11, fragment: AACGAG
```

Dla wszystkich Sekwencji o progu **>=32** i długości **6** :

```
./exe3 ./dane/seq3.fasta ./dane/seq3.qual 33 6  
Nie wygenerowano zadnych wierzchołkow. Spróbuj obniżyć prog wiarygodności.
```

Wnioski:

- Przy progu **20** algorytm znalazł fragment **AGATTA** w wszystkich 5 sekwencjach, więc motyw był dobrze zachowany po filtracji.
- Przy progu **25** wynik spadł do **4** sekwencji (brak sekwencji 5), a fragment zmienił się na **ATACTT** – widać, że filtracja usuwa część motywu.
- Przy progu **30** zostają już tylko **3** sekwencje (1, 3, 4) z fragmentem **ACTATA** – motyw dalej jest „trafiony”, ale coraz mniej kompletne dane przetrwają filtr.
- Przy progu **32** pojawia się tylko jedna sekwencja bo, tylko ta kombinacja była możliwa po usunięciu wszystkich nukleotydów z liczbą progów mniejszą niż 32.
- Przy progach **>= 33** nie powstają wierzchołki, bo po odrzuceniu słabych pozycji nie da się już zbudować **6-merów**.