

[3]Sprawozdanie

Zadanie III

Wydział i kierunek:	WliT, Bioinformatyka
Imię i nazwisko prowadzącego: Prof. Dr. hab. Inż. Marta Kasprzak	Data oddania sprawozdania:
Imię i nazwisko: Kacper Gałaj 163827	Ocena:

1. Opis zastosowanego algorytmu

W programie zastosowałem algorytm **zachłannego budowania kłiki** do wyboru najlepszego zestawu pasujących fragmentów sekwencji. Algorytm został wybrany ze względu na prostotę i szybkie działanie. Mimo że nie gwarantuje rozwiązania optymalnego, w praktyce daje poprawne i wystarczająco dobre wyniki.

Poniżej pseudokod demonstrujący podstawowe użycie algorytmu:

Algorytm GreedyMaximalCliqueInGroup

Wejście:

group_nodes, nodes, seq_count, distance_limit

Wyjście:

clique - lista wybranych wierzchołków

1. Dla każdego v w `group_nodes` oblicz `degree[v]` jako liczbę kompatybilnych sąsiadów
2. Posortuj `group_nodes` malejąco według `degree[v]`
3. `clique` = pusty zbiór
`used_seq` = tablica fałsz o rozmiarze `seq_count`
4. Dla każdego v z posortowanej listy:
jeśli `used_seq[v.seq_index] = false`
i v jest kompatybilny ze wszystkimi w `clique`:
dodaj v do `clique`
`used_seq[v.seq_index] = true`
5. Zwróć `clique`

Złożoność algorytmu:

Fragment obliczania stopni wykonuje porównanie każdej pary wierzchołków w danej grupie `group_nodes`, co daje złożoność czasową **$O(n^2)$** , gdzie k to liczba wierzchołków w grupie.

```
vector<int> degrees(nodes.size(), 0);
for (size_t i = 0; i < group_nodes.size(); ++i) {
    int idx_i = group_nodes[i];
    for (size_t j = i + 1; j < group_nodes.size(); ++j) {
        int idx_j = group_nodes[j];
        if (are_compatible(nodes[idx_i], nodes[idx_j], distance_limit)) {
            degrees[idx_i] += 1;
```

```
        degrees[idx_j] += 1;
    }
}
}
```

Źródło.

O Algorytmie dowiedziałem się przez film na youtube z kanału "Wrath of Math" autor przechodzi od tłumaczenia czym są Kliki, oraz tłumaczy w pełni działanie tego oto algorytmu.

<https://www.youtube.com/watch?v=gjRcTH2p65c> -

Maksymalna Klika

<https://www.youtube.com/watch?v=nBrFC0STAp0> - Czym są kliki

[1] TEST: Motyw z drobnymi podstawieniami (0–2 zmiany)
Instancja nr 1 [seq1] Użyty motyw: ATTAGCTTATACGTGG

Cel:

Sprawdzić, czy algorytm potrafi wykryć wspólny, niezmienny motyw obecny po jednym razie w każdej sekwencji po filtracji jakości. To jest punkt odniesienia do późniejszych testów z mutacjami i różnymi parametrami.

▼ Fasta

```
>DOJHLOP02GVZDE length=96 xy=2707_2112 region=2
run=R_2005_09_08_15_35_38_
TTACTTATGTTTGAACATAGTGTTATTAGCTTATACGTGG
CTGAAGCTTGTGCTTCGATT
CTATGGAGGGATGCTGGCAAGGCTCCGGAAGCAGCA
>DOJHLOP01BGY5C length=99 xy=0486_1118 region=1
run=R_2005_09_08_15_35_38_
TTCCCCTATTACAATTAGCTTATACGTGGCTTTAAGCCT
AAACATTTCTCGTAGATTAC
TGCGATTGCCTCTCCTTGTCTTGTCTTCTGCTATGAG
>DOJHLOP01BP4NK length=113 xy=0590_2174 region=
1 run=R_2005_09_08_15_35_38_
CATGGTCCATCAGCCTCAAAGCCTTTCTGTAGCCTCCA
GGTTTTGATTAGCTTATACGTG
GTGCAACATTCTCTTTTGTATCTCTTACCTTTTTTTGTTG
TCCAAATTAAAAGG
>DOJHLOP01ANFAH length=102 xy=0149_2711 region=
1 run=R_2005_09_08_15_35_38_
ATTACATACAGATGTTTTGTGATGATTGGGTTGAATTACA
TATTAGCTTATACGTGGCTG
ATGATCAAGCTCTAATAGGGAGGGTTAGCTCGAATAGG
GTAG
>DOJHLOP01BQUH1 length=94 xy=0598_2903 region=
1 run=R_2005_09_08_15_35_38_
TCTTCTCGCCTTCGTGCTGCAAGTGTTTCTAATTGCAA
ATTAGCTTATACGTGGTCAACT
TCTGAATCTCTTGCTAATTCTCTGATTTGATCAA
```

▼ Qual

>DOJHLOP02GVZDE length=96 xy=2707_2112 region=2
run=R_2005_09_08_15_35_38_

26 24 28 31 28 26 31 30 31 29 28 16 32 31 27 30 17 31 3
0 31 18 32 27 27 ** 18 31 31 17 30 31 31 29 26 32 30 31
26 32 29 28 ** 17 26 27 28 22 30 29 29 26 31 30 31 32
30 27 32 29 27

30 27 31 29 27 28 23 22 30 28 27 18 26 31 27 32 30 31
27 32 29 23 31 27 25 18 29 24 26 24 30 27 31 30 31 32
31 25

>DOJHLOP01BGY5C length=99 xy=0486_1118 region=1
run=R_2005_09_08_15_35_38_

29 24 24 24 18 2 30 31 29 24 23 31 24 ** 29 29 24 31 3
0 30 25 31 27 27 31 26 29 24 25 18 ** 31 27 26 13 31 27
30 29 24 32 29 28 17 32 31 27 26 13 32 29 30 31 28 30
28 31 29 24 32

31 31 31 30 29 28 31 28 22 32 30 25 32 32 31 27 20 29
24 31 32 26 20 31 28 30 31 27 30 31 28 32 28 31 32 30
29 26 25 21 27

>DOJHLOP01BP4NK length=113 xy=0590_2174 region=
1 run=R_2005_09_08_15_35_38_

31 29 29 31 28 32 31 28 31 29 29 31 32 30 27 31 30 28
27 15 32 31 28 29 28 18 32 32 31 31 31 32 29 26 31 31 2
8 25 27 25 24 24 22 12 31 ** 28 25 29 31 31 31 27 28 27
19 31 28 28 19 31 28 ** 22 32 29 30 26 31 29 27 25 31 1
8 31 24 24 21 12 30 31 31 32 28 31 28 23 16 31 30 25 20
20 19 16 9 1 31 28 23 31 29 30 26 23 22 2 31 28 24 23 2
1 12 25 23

>DOJHLOP01ANFAH length=102 xy=0149_2711 region=
1 run=R_2005_09_08_15_35_38_

31 30 26 27 31 31 29 26 32 31 31 31 30 32 24 24 22 12 3

```

1 25 29 27 32 32 32 31 28 28 27 19 30 27 31 31 28 28 2
6 26 31 31 31 ** 29 26 29 29 31 31 30 24 23 31 28 30 2
9 27 31 27 ** 32 32 27 32 31 26 32 29 32 31 28 32 24 2
7 31 21 29 27 32 31 23 22 2 30 28 27 19 30 28 22 32 27
31 32 24 29 27 17 23 23 22 5 31 25 32
>DOJHLOP01BQUH1 length=94 xy=0598_2903 region=
1 run=R_2005_09_08_15_35_38_
32 31 31 28 31 31 32 31 27 21 31 27 31 31 32 31 31 31 29
28 26 20 31 24 24 26 25 10 27 29 26 19 31 27 28 29 24
24 ** 18 2 31 30 26 31 31 31 30 31 29 28 22 32 32 31 **
29 29 26 19 31 31 26 25 15 29 22 13 19 30 27 26 28 23
29 32 25 24 17 31 27 31 31 21 29 31 21 29 28 16 25 27 2
5 28 31 28

```

Proces przetwarzania

- Najpierw odrzuca wszystkie pozycje o **jakości < 25**, tworząc przefiltrowane sekwencje.
- Z przefiltrowanych sekwencji buduje wszystkie k-mery długości **k=6**.
- Dla każdego identycznego k-meru tworzy grupę wierzchołków i łączy je krawędziami, jeśli są z różnych sekwencji i mają zbliżone pozycje ($\leq 10 \cdot k$).
- Następnie algorytm zachłanny wybiera klikę (**po jednym wierzchołku z każdej sekwencji**), maksymalizując rozmiar.

Wynik dla Sekwencji o progu **25 i długości **6** :**

```
./exe3 ./dane/seq1.fasta ./dane/seq1.qual 25 6
Znaleziono strukture o rozmiarze 4:
Sekwencja 2 (D0JHLOP01BGY5C length=99 xy=0486_1118 region=1 run=R_2005_0
_08_15_35_38_), pozycja 17, fragment: AGCTTA
Sekwencja 5 (D0JHLOP01BQUH1 length=94 xy=0598_2903 region=1 run=R_2005_0
_08_15_35_38_), pozycja 42, fragment: AGCTTA
Sekwencja 4 (D0JHLOP01ANFAH length=102 xy=0149_2711 region=1 run=R_2005_
9_08_15_35_38_), pozycja 45, fragment: AGCTTA
Sekwencja 3 (D0JHLOP01BP4NK length=113 xy=0590_2174 region=1 run=R_2005_
9_08_15_35_38_), pozycja 49, fragment: AGCTTA
```

Wnioski

- Algorytm znalazł wspólny k-mer **AGCTTA** w 4 sekwencjach (2, 5, 4, 3), więc zwrócił strukturę rozmiaru 4.
- Podane pozycje (17, 42, 45, 49) to pozycje startu tego k-meru w oryginalnych sekwencjach.
- Sekwencja 1 nie weszła, bo przy progu 25 w jej przefiltrowanej sekwencji nie ma **AGCTTA**, więc w grafie nie było wierzchołka do dołączenia.
- **AGCTTA** jest fragmentem wstawionego motywu, więc wynik faktycznie wskazuje na motyw, tylko w skróconej postaci (k=6).

[2] TEST: Zależność od długości k-meru (k = 4, 6, 8, 9)

Instancja nr 2 **[seq2]** Użyty motyw:
AGGATCACCTATAT

Cel:

Zbadać wpływ długości podciągu na skuteczność detekcji.
Krótsze k-mery powinny być łatwiejsze do znalezienia, ale

mniej charakterystyczne (więcej przypadkowych trafień), natomiast dłuższe k-mery są bardziej specyficzne, ale łatwiej „giną” po filtracji jakości lub przez mutacje.

▼ Fasta

```
>DOJHLOP01BDHIH length=100 xy=0446_2135 region=
1 run=R_2005_09_08_15_35_38_
GCGCATTGGGGATAGGCGTCGCAGACAGGTTACTTATG
TTTGAACATAGTG**AGGATCACCTATAT**AGCCCTGAA
GCTTGTGCTTCGATTCTATGGAGGGA
>DOJHLOP01DQU8O length=99 xy=1419_0278 region=1
run=R_2005_09_08_15_35_38_
GAGCTTATGCAGGGCTCATAGCAGAAGAA**AGGATCAC
CTATAT**GGCAATCGCAGTGAATCTACGAGAAATGTTTA
GGCTTAAAGTTCCAATAATTGCAA
>DOJHLOP01A0CMG length=110 xy=0296_3670 region
=1 run=R_2005_09_08_15_35_38_
TAGTGAAAATTCCGTCCTTTTTTAATTGGACAACAAAAG
GTAGAGATACAAAAGAGAATG**AGGATCACCTATAT**G
GCATGGCAAAACCTGGAGGCTACAAGAAGCTTGAG
>DOJHLOP02G64JC length=99 xy=2834_1830 region=
2 run=R_2005_09_08_15_35_38_
CTATTCGAGCTAACCC**AGGATCACCTATAT**GATCAT
CAGTTCCGTTTCCTGTCTCCATGTAATTCAACCCAATCAT
CAACAAAACATCTGTATGTAATCG
>DOJHLOP02HLL3Q length=103 xy=2999_1940 region
=2 run=R_2005_09_08_15_35_38_
TACCTTTGATTACTGATAC**AGGATCACCTATAT**ATAT
```


TTTAATCAAGACTCTTAATAGGTTGCCAGAAAATATGCC
GATATGGATGATGCCATCTCAATCGA

▼ Qual

>DOJHLOP01BDHIH length=100 xy=0446_2135 region=
1 run=R_2005_09_08_15_35_38_

27 32 32 31 32 31 27 25 25 20 7 30 29 32 30 26 31 31 3
2 31 31 32 24 32 30 31 30 31 26 31 27 29 30 31 27 29 3
2 32 26 25 10 31 22 13 29 30 31 32 31 30 29 ** 29 28 17
29 31 31 31 29 32 30 26 32 31 30 ** 25 31 29 28 17 31 3
1 24 16 31 32 30 27 30 32 31 31 30 27 32 30 29 31 28 3
2 30 29 30 24 23 31 28 28 18 25

>DOJHLOP01DQU8O length=99 xy=1419_0278 region=1
run=R_2005_09_08_15_35_38_

27 26 31 30 30 26 26 30 30 30 29 26 25 11 31 29 32 31
26 30 30 29 28 32 30 27 29 31 27 ** 31 31 28 26 20 30
26 31 28 30 26 31 31 31 ** 27 21 31 30 25 27 31 31 29 3
0 29 27 28 28 22 31 27 26 22 26 30 20 24 26 25 9 20 2
6 23 22 3 31 22 13 29 31 28 27 27 13 22 22 14 27 21 29
26 29 27 25 21 11 30 31 28 22

>DOJHLOP01A0CMG length=110 xy=0296_3670 region
=1 run=R_2005_09_08_15_35_38_

24 27 17 17 31 24 24 19 4 18 8 18 7 31 30 22 13 22 22 20
13 2 31 28 31 28 27 20 20 28 31 27 30 22 22 21 15 5 27
21 28 18 29 23 28 32 31 17 28 26 25 22 11 32 31 31 24 1
7 30 32 ** 31 26 31 24 31 28 31 25 24 8 31 25 25 18 ** 3
1 26 32 25 32 31 26 24 25 25 20 7 27 20 27 27 21 22 21
11 26 25 31 29 21 12 31 23 22 17 23 23 22 29 31 18

>DOJHLOP02G64JC length=99 xy=2834_1830 region=

```

2 run=R_2005_09_08_15_35_38_
31 32 31 31 27 32 31 29 32 31 32 31 27 28 28 18 ** 32 3
0 27 32 30 31 27 30 31 28 31 32 29 26 ** 30 30 32 32 3
1 27 32 28 29 29 26 27 25 32 30 27 31 27 29 31 28 21 2
7 1 27 28 30 31 25 30 25 31 26 17 31 27 28 28 18 30 26
30 31 32 31 24 22 13 31 25 25 22 13 32 26 30 32 32 31
31 32 31 30 32 31 27 28 32 24
>DOJHLOP02HLL3Q length=103 xy=2999_1940 region
=2 run=R_2005_09_08_15_35_38_
32 26 31 26 29 28 16 31 32 31 27 26 29 31 32 32 19 32
32 ** 13 13 13 12 11 8 5 1 32 30 31 32 26 25 ** 22 10 25
21 26 25 22 11 29 27 32 31 30 27 28 32 32 21 32 31 27 2
4 22 28 32 31 28 27 30 30 24 17 31 24 24 22 13 29 31 2
5 29 29 24 29 30 32 28 31 31 27 27 31 26 32 30 32 31 2
7 30 31 30 25 27 30 24 32 32 29 32

```

Wynik dla Sekwencji o progu **25 i długości **4** :**

```

> ./exe3 ./dane/seq2.fasta ./dane/seq2.qual 25 4
Znaleziono strukture o rozmiarze 4:
Sekwencja 4 (DOJHLOP02G64JC length=99 xy=2834_1830 region=2 run=R_2005_09_08_15_35_38_), pozycja 23, fragment: ACCT
Sekwencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 36, fragment: ACCT
Sekwencja 5 (DOJHLOP02HLL3Q length=103 xy=2999_1940 region=2 run=R_2005_09_08_15_35_38_), pozycja 18, fragment: ACCT
Sekwencja 1 (DOJHLOP01BDHIH length=100 xy=0446_2135 region=1 run=R_2005_09_08_15_35_38_), pozycja 58, fragment: ACCT

```

Wynik dla Sekwencji o progu **25 i długości **6** :**

```
./exe3 ./dane/seq2.fasta ./dane/seq2.qual 25 6
Znaleziono strukture o rozmiarze 4:
Sekwencja 5 (DOJHLOP02HLL3Q length=103 xy=2999_1940 region=2 run=R_2005_09_08_15_35_38_), pozycja 18, fragment: ACCTAT
Sekwencja 4 (DOJHLOP02G64JC length=99 xy=2834_1830 region=2 run=R_2005_09_08_15_35_38_), pozycja 23, fragment: ACCTAT
Sekwencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 36, fragment: ACCTAT
Sekwencja 1 (DOJHLOP01BDHIH length=100 xy=0446_2135 region=1 run=R_2005_09_08_15_35_38_), pozycja 58, fragment: ACCTAT
```

Wynik dla Sekwencji o progu **25** i długości **8** :

```
./exe3 ./dane/seq2.fasta ./dane/seq2.qual 25 8
Znaleziono strukture o rozmiarze 4:
Sekwencja 5 (DOJHLOP02HLL3Q length=103 xy=2999_1940 region=2 run=R_2005_09_08_15_35_38_), pozycja 18, fragment: ACCTATAT
Sekwencja 4 (DOJHLOP02G64JC length=99 xy=2834_1830 region=2 run=R_2005_09_08_15_35_38_), pozycja 23, fragment: ACCTATAT
Sekwencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 36, fragment: ACCTATAT
Sekwencja 1 (DOJHLOP01BDHIH length=100 xy=0446_2135 region=1 run=R_2005_09_08_15_35_38_), pozycja 58, fragment: ACCTATAT
```

Wynik dla Sekwencji o progu **25** i długości **9** :

```
./exe3 ./dane/seq2.fasta ./dane/seq2.qual 25 9
Znaleziono strukture o rozmiarze 3:
Sekwencja 4 (DOJHLOP02G64JC length=99 xy=2834_1830 region=2 run=R_2005_09_08_15_35_38_), pozycja 22, fragment: CACCTATAT
Sekwencja 2 (DOJHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 35, fragment: CACCTATAT
Sekwencja 1 (DOJHLOP01BDHIH length=100 xy=0446_2135 region=1 run=R_2005_09_08_15_35_38_), pozycja 57, fragment: CACCTATAT
```

Wnioski:

- Im większe k, tym trudniej znaleźć wspólny fragment we wszystkich sekwencjach, bo dłuższy k-mer częściej „rozrywa się” po filtracji jakości.

- Krótsze k-mery dają więcej dopasowań, ale są mniej specyficzne; dłuższe są bardziej precyzyjne, ale liczba trafionych sekwencji spada.
- Co ciekawe, przy `k=9` struktura ma rozmiar tylko `3`, bo w dwóch sekwencjach po filtracji jakości **nie zachował się dokładny fragment** `CACCTATAT`, więc nie mogły wejść do wyniku.
- Wyniki potwierdzają, że dobór k to kompromis między „czułością” (ile sekwencji złapie) a „precyzją” (jak długi i jednoznaczny jest motyw).

[3] TEST: Wpływ progu jakości (20 / 25 / 30)

Instancja nr 3 `[seq3]` Użyty motyw:
TATACTTAGATTA

Cel:

Ustalić, dla jakiego progu jakości program jeszcze znajduje motyw w większości sekwencji, a od jakiej wartości progu zaczyna on znikać z wyniku.

▼ Fasta

```
>DOJHLOP02IRJPW length=104 xy=3477_0514 region=
2 run=R_2005_09_08_15_35_38_
AATAGGGGAAGGTGGCTCTGGTGGCGCATTGGGGATAG
GCGTC**TATACTTAGATTA**TTATGTTTGAATATACTTA
GATTACAGTTGCAAGCCCTGAAGCTTGTG
>DOJHLOP01DQU8O length=99 xy=1419_0278 region=1
```

```

run=R_2005_09_08_15_35_38_
GAGCTTATGCAGGGCTCATAGCAGAAGAACAAGGACAA
GGAGAGGCA**TATACTTAGATTA**TACGAGAAATGTTTA
GGCTTATATACTTAGATTATGCAA
>DOJHLOP02FEHEE length=119 xy=2098_0516 region=
2 run=R_2005_09_08_15_35_38_
TCTGTAGCCTCCAGGTTTTGCCATGCCAAAGTTTCTTG
CAACATTCTCTTTTGTATCTCTACCTTTTTTG**TATACTT
AGATTA**AGGACGGATTTTTTCATATACTTAGATTAACCC
TCCTA
>DOJHLOP02IBLTK length=97 xy=3295_2214 region=2
run=R_2005_09_08_15_35_38_
AAGGCCTAGCACACTCGATTACATACAGATGTT**TATAC
TTAGATTA**GTTGAATTACATGGAGACAGGTATACTTAG
ATTAATCAAGCTCTAATAGGG
>DOJHLOP01CJL9T length=114 xy=0926_1775 region=1
run=R_2005_09_08_15_35_38_
TTCTCTGATTTGATCAATCTGATTCTCTAATTCAACAAG
TAGGTTTTTCAAATTCGAGGAGAAAACGTCTAGCCA**T
ATACTTAGATTA**TAACCTATACTTAGATTAGTTAATGT

```

▼ Qual

```

>DOJHLOP02IRJPW length=104 xy=3477_0514 region=
2 run=R_2005_09_08_15_35_38_
31 27 31 28 26 25 22 10 30 25 28 25 29 31 27 32 28 30
32 29 26 30 30 27 32 32 32 31 31 27 25 25 22 12 28 28
32 31 27 31 31 31 30 ** 31 32 30 31 32 27 31 31 26 29 2
6 32 30 ** 31 27 31 30 32 29 28 17 31 25 18 30 32 28 31
31 24 30 27 27 13 27 31 32 31 28 28 31 27 31 30 29 23

```

32 29 28 18 31 31 24 16 25 30 27 25 24 27 22
>DOJHLOP01DQU8O length=99 xy=1419_0278 region=1
run=R_2005_09_08_15_35_38_
27 26 31 30 30 26 26 30 30 30 29 26 25 11 31 29 32 31
26 30 30 29 28 32 30 27 29 31 27 31 31 28 26 20 30 26
31 28 30 26 31 31 31 27 21 31 30 ** 25 27 31 31 29 30 2
9 7 28 28 22 31 27 ** 26 22 26 30 20 24 26 25 9 20 26
23 22 3 31 22 13 29 31 28 27 27 13 22 22 14 27 21 29 2
6 29 27 25 21 11 30 31 28 22
>DOJHLOP02FEHEE length=119 xy=2098_0516 region=
2 run=R_2005_09_08_15_35_38_
31 32 32 32 31 29 29 31 26 32 31 27 29 31 27 25 25 21
9 32 30 26 31 29 31 30 26 27 27 18 31 28 27 15 32 31 2
6 30 31 30 26 28 30 31 26 31 30 29 25 25 22 10 30 30
31 31 32 31 31 22 31 31 27 21 21 20 16 9 32 ** 31 26 27 3
2 31 27 26 24 31 27 24 24 21 ** 13 31 27 26 32 30 26 31
22 22 21 15 5 31 25 26 19 32 32 27 21 31 31 22 26 32 31
30 27 28 28 18 31 26 19 31 27
>DOJHLOP02IBLTK length=97 xy=3295_2214 region=2
run=R_2005_09_08_15_35_38_
31 27 30 25 31 27 31 31 31 30 32 31 32 32 31 31 32 32 3
1 26 28 28 31 31 29 31 28 32 31 29 29 25 25 ** 22 12 32
31 32 27 31 31 32 28 25 28 27 ** 18 30 27 32 30 25 26
24 28 32 32 32 26 24 22 30 32 31 29 27 24 31 27 28 31
26 30 25 31 31 31 32 32 30 31 27 32 31 27 30 29 27 25
30 29 27 31 30 24 22 5
>DOJHLOP01CJL9T length=114 xy=0926_1775 region=1
run=R_2005_09_08_15_35_38_
31 28 28 31 32 31 32 32 29 28 18 32 31 29 31 31 28 31 2
6 32 29 25 31 27 31 31 29 25 31 26 31 26 31 31 28 31 30
26 28 11 27 24 16 22 22 21 15 5 32 27 26 13 31 28 31 24

31 31 27 18 32 25 24 20 6 30 29 32 30 26 26 32 30 26
26 ** 24 31 7 7 7 6 6 5 4 3 1 1 31 ** 26 30 27 31 28 29 2
8 18 26 32 22 14 31 31 26 26 24 25 19 31 28 31 27 29 31
32

**Wynik dla Sekwencji o progu 20 i
długości 6 :**

```
./exe3 ./dane/seq3.fasta ./dane/seq3.qual 20 6  
Znaleziono strukture o rozmiarze 5:  
Sekwencja 1 (D0JHLOP02IRJPW length=104 xy=3477_0514 region=2 run=R_2005_09_08_15_35_38_), pozycja 51, fragment: AGATTA  
Sekwencja 5 (D0JHLOP01CJL9T length=114 xy=0926_1775 region=1 run=R_2005_09_08_15_35_38_), pozycja 101, fragment: AGATTA  
Sekwencja 2 (D0JHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 55, fragment: AGATTA  
Sekwencja 4 (D0JHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_35_38_), pozycja 75, fragment: AGATTA  
Sekwencja 3 (D0JHLOP02FEHEE length=119 xy=2098_0516 region=2 run=R_2005_09_08_15_35_38_), pozycja 77, fragment: AGATTA
```

**Wynik dla Sekwencji o progu 25 i
długości 6 :**

```
./exe3 ./dane/seq3.fasta ./dane/seq3.qual 25 6  
Znaleziono strukture o rozmiarze 4:  
Sekwencja 1 (D0JHLOP02IRJPW length=104 xy=3477_0514 region=2 run=R_2005_09_08_15_35_38_), pozycja 45, fragment: ATACTT  
Sekwencja 2 (D0JHLOP01DQU80 length=99 xy=1419_0278 region=1 run=R_2005_09_08_15_35_38_), pozycja 49, fragment: ATACTT  
Sekwencja 4 (D0JHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_35_38_), pozycja 69, fragment: ATACTT  
Sekwencja 3 (D0JHLOP02FEHEE length=119 xy=2098_0516 region=2 run=R_2005_09_08_15_35_38_), pozycja 71, fragment: ATACTT
```

**Wynik dla Sekwencji o progu 30 i
długości 6 :**

```
Znaleziono strukture o rozmiarze 3:  
Sekwencja 1 (DOJHLOP02IRJPW length=104 xy=3477_0514 region=2 run=R_2005_09_08_15_35_38_), pozycja 47, fragment: ACTATA  
Sekwencja 4 (DOJHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_35_38_), pozycja 63, fragment: ACTATA  
Sekwencja 3 (DOJHLOP02FEHEE length=119 xy=2098_0516 region=2 run=R_2005_09_08_15_35_38_), pozycja 90, fragment: ACTATA
```

Wynik dla Sekwencji o progu **32** i długości **6**:

```
./exe3 ./dane/seq3.fasta ./dane/seq3.qual 32 6  
Znaleziono strukture o rozmiarze 2:  
Sekwencja 5 (DOJHLOP01CJL9T length=114 xy=0926_1775 region=1 run=R_2005_09_08_15_35_38_), pozycja 5, fragment: CGAGTC  
Sekwencja 4 (DOJHLOP02IBLTK length=97 xy=3295_2214 region=2 run=R_2005_09_08_15_35_38_), pozycja 14, fragment: CGAGTC
```

Dla wszystkich Sekwencji o progu **>=32** i długości **6**:

```
./exe3 ./dane/seq3.fasta ./dane/seq3.qual 33 6  
Nie wygenerowano zadnych wierzchołkow. Spróbuj obniżyć prog wiarygodności.
```

Wnioski:

- Przy progu **20** algorytm znalazł fragment **AGATTA** w wszystkich 5 sekwencjach, więc motyw był dobrze zachowany po filtracji.
- Przy progu **25** wynik spadł do **4** sekwencji (brak sekwencji 5), a fragment zmienił się na **ATACTT** — widać, że filtracja usuwa część motywu.
- Przy progu **30** zostają już tylko **3** sekwencje (1, 3, 4) z fragmentem **ACTATA** — motyw dalej jest „trafiony”, ale coraz mniej kompletne dane przetrwają filtr.

- Przy progu **32** pojawia się tylko **2**-elementowa struktura z fragmentem **CGAGTC**, czyli nie z motywu — to znak, że motyw zniknął po filtracji i algorytm łąpie przypadkowy wspólny 6-mer.
- Przy progach **33** i **35** nie powstają wierzchołki, bo po odrzuceniu słabych pozycji nie da się już zbudować **6-merów**.